

MÁSTER UNIVERSITARIO EN CIENCIA DE DATOS



TRABAJO FIN DE MÁSTER

Sistema de búsqueda inteligente
mediante técnicas RAG aplicado
a documentos sobre la gestión
empresarial (MBA)

Autor

Nicolás Camaño Antolín

TUTORES

Emilio Soria Olivas

JUNIO, 2025

Resumen

Este es el resumen en español del TFM. Aquí irán brevemente descritos los objetivos, metodología, resultados y conclusiones principales.

Abstract

This is the abstract of the TFM. Here will be a summarize of the objectives, methodology, main results, and conclusions in English.

Keywords

Palabras clave: investigación, ciencia de datos, machine learning, etc.

Índice general

1. Introducción	1
1.1. Contexto	1
1.2. Motivación	2
1.3. Objetivos	3
2. Marco teórico	4
2.1. Concepto de Inteligencia Artificial Generativa	4
2.2. Procesado del Lenguaje Natural	4
2.3. Retrieval Augmented Generation	7
2.3.1. Recuperación de la información	7
2.3.2. Generación de la respuesta	11
2.3.3. Evaluación de modelos	11

Capítulo 1

Introducción

1.1. Contexto

Con el auge de las nuevas tecnologías y la expansión del mundo digital, no sólo en las organizaciones sino también en la vida cotidiana de los individuos de la sociedad, resulta cada vez un desafío más complejo gestionar volúmenes de datos exponencialmente crecientes. En tan sólo un par de décadas el desafío ha pasado de ser encontrar el lugar donde dar con la información que se desea a encontrar las fuentes, entre todas las disponibles, que mejor se apropian a los objetivos y necesidades de dicha búsqueda. Los programas de Máster in Business Administration (MBA) generan una gran cantidad de documentación que incluye casos de estudio, análisis estratégicos, marcos teóricos, mejores prácticas y metodologías de gestión empresarial entre muchos otros temas. La constante publicación de documentos de este ámbito contribuye a consolidación de un activo intelectual de incalculable valor que, en gran cantidad de ocasiones, permanece infrautilizado debido a los sistemas tradicionales de búsqueda y recuperación de información.

En una gran cantidad de ocasiones, los métodos convencionales de búsqueda por palabras clave resultan insuficientes para abordar la complejidad semántica y conceptual. Los profesionales de la materia, o incluso los estudiantes, requieren acceder no sólo a la información específica de los documentos disponibles, sino también al conocimiento contextualizado que les permita comprender las relaciones o significados de diferentes conceptos, teorías y prácticas. Es por ello que, en relación a éste último tipo de búsqueda mencionado, dar con la información requerida en extensos repositorios de documentos lleva un tiempo valioso y en ocasiones sin los resultados óptimos.

Como propuesta de mejora a los métodos tradicionales de búsqueda, en el mundo de la inteligencia artificial se proponen las técnicas Retrieval Augmented Generation (RAG). Estas permiten combinar la capacidad de recuperación de información de sistemas tradicionales con la comprensión semántica avanzada de modelos de lenguaje natural, dando lugar a una interacción más natural e intuitiva con el mundo de la gestión empresarial.

La relevancia de este proyecto nace en la necesidad creciente de herramientas para ámbitos específicos que faciliten el aprendizaje continuo y contextualizado. Un sistema de búsqueda inteligente específicamente diseñado para documentos de MBA contribuirá a mejorar la eficiencia en la consulta de información especializada. Además, la actual disponibilidad de tecnologías de procesamiento de lenguaje natural y la madurez de las técnicas de recuperación de información crean un momento propicio para el desarrollo

de soluciones innovadoras en este dominio. La convergencia de estos factores tecnológicos con la demanda creciente de sistemas de gestión del conocimiento más sofisticados establece el marco ideal para el desarrollo de esta investigación.

1.2. Motivación

El ecosistema de la gestión empresarial ha experimentado un crecimiento en los últimos años. Según AACSB (Association to Advance Collegiate Schools of Business) alrededor de 660.000 estudiantes se encuentran matriculados en programas MBA en todo el mundo. Lo que convierte a este título de postgrado en uno de los más cursados. [1]

Cada programa de MBA genera anualmente una cantidad considerable de documentación académica y práctica. Teniendo en cuenta los miles de programas acreditados que existen, en cada uno de ellos se genera continuamente documentación sobre casos de estudio, investigaciones, análisis sectoriales, trabajos de fin de máster y más material didáctico. La magnitud de esta información presenta un desafío significativo debido al constante crecimiento del volumen de conocimiento. Esta problemática se ve agravada por la necesidad de los profesionales y estudiantes de acceder rápidamente a información específica y contextualizada en un entorno empresarial caracterizado por la toma de decisiones acelerada, donde el tiempo invertido en procesos de búsqueda manual puede representar una desventaja competitiva significativa.

Mediante el uso de técnicas RAG (Retrieval-Augmented Generation), que emergen como una solución revolucionaria y sofisticada a las limitaciones de los métodos de búsqueda tradicionales basados en palabras clave, sería posible obtener diversas mejoras transformadoras en el proceso de gestión del conocimiento académico-empresarial. Una de las ventajas más destacadas de estos sistemas radica en su capacidad para reducir drásticamente el tiempo de consulta, transformando procesos que tradicionalmente requieren horas de investigación manual en consultas que pueden resolverse en cuestión de minutos o incluso segundos. En primer lugar, se puede proporcionar una comprensión contextual avanzada ya que estas técnicas identifican las relaciones semánticas complejas existentes entre conceptos aparentemente dispares, permitiendo descubrir conexiones ocultas entre teorías de gestión, casos de estudio y marcos conceptuales desarrollados en diferentes contextos geográficos y temporales. En segundo lugar, se consigue sintetizar el conocimiento procedente de diferentes fuentes heterogéneas, agregando valor significativo al proceso de consulta de la información mediante la generación de respuestas coherentes y fundamentadas que integran múltiples perspectivas académicas y prácticas.

Adicionalmente, la implementación de sistemas RAG en el ámbito MBA facilitaría la personalización del aprendizaje según las necesidades específicas de cada estudiante o programa, permitiría la identificación de lagunas en el conocimiento existente, aceleraría los procesos de investigación académica al proporcionar acceso inteligente a precedentes relevantes, y contribuiría a la democratización del acceso al conocimiento empresarial de alta calidad, independientemente de la ubicación geográfica o los recursos institucionales disponibles. La optimización temporal que proporciona esta tecnología permite a ejecutivos, estudiantes e investigadores dedicar más tiempo al análisis crítico, la reflexión estratégica y la implementación de soluciones, liberando recursos valiosos que anteriormente se invertían en procesos de búsqueda y síntesis manual de información. Esta transformación tecnológica representa una oportunidad

única para revolucionar la forma en que se genera, almacena, procesa y transmite el conocimiento en el ámbito de la gestión empresarial, estableciendo nuevos estándares de eficiencia y efectividad en la educación ejecutiva del siglo XXI.

1.3. Objetivos

Como bien se refleja en el título del proyecto, el propósito general se basa en desarrollar e implementar un sistema de búsqueda inteligente basado en técnicas de Retrieval-Augmented Generation que sea capaz de recuperar de manera eficiente y contextualizada información especializada en el ámbito de aplicación del proyecto, documentos de gestión empresarial. Para lograr este propósito, se pretende satisfacer diferentes objetivos específicos que abarcan las diferentes dimensiones del proyecto. Estos se engloban en objetivos técnicos, funcionales y de investigación.

Con objetivos técnicos se entiende el diseño de una arquitectura robusta que integre componentes de recuperación de información, procesamiento del lenguaje natural y generación de respuestas optimizadas para el dominio de la gestión empresarial. En esta arquitectura se deberán incorporar técnicas avanzadas de procesamiento semántico mediante algoritmos de embeddings y similitud semántica que capturen las relaciones conceptuales complejas presentes en la literatura utilizada. Además, para garantizar un correcto funcionamiento de la herramienta se tendrá que crear un corpus de documentos suficientemente enriquecido como para capturar todo el conocimiento deseado. Y, se deberán hacer pruebas de funcionamiento con tal de ajustar y capturar los hiperparámetros del modelo para maximizar la precisión y relevancia de las respuestas.

Con objetivos funcionales se pretende diseñar y llevar a cabo una evaluación comprensiva del rendimiento del sistema mediante métricas cuantitativas y cualitativas y comparándolo con los métodos de búsqueda tradicionales. Además, para aportar un valor añadido a la solución se creará una interfaz de usuario que facilite la interacción con el modelo donde se presenten los resultados de una manera clara y estructurada. Y, se desplegará el proyecto en un entorno de producción. Por último, se demostrará la viabilidad y utilidad de la herramienta mediante casos de uso reales que evidencien las mejoras tangibles en los procesos de acceso a la información.

Para finalizar, con objetivos de investigación se pretende complementar el proyecto desde una dimensión crítica y prospectiva. Con ello, se pretende identificar y documentar las principales limitaciones técnicas y conceptuales del enfoque RAG aplicado al dominio MBA, así como los desafíos específicos relacionados con la heterogeneidad y complejidad de los contenidos empresariales. Este análisis crítico facilitará el establecimiento de recomendaciones técnicas y metodológicas para el perfeccionamiento del sistema, además de identificar oportunidades de investigación que contribuyan al avance del estado del arte en sistemas de recuperación inteligente para dominios especializados.

Capítulo 2

Marco teórico

2.1. Concepto de Inteligencia Artificial Generativa

La inteligencia artificial generativa, dentro del ecosistema de la inteligencia artificial, engloba todo un conjunto de métodos y técnicas diseñadas para generar nuevo contenido a partir de información previamente existente, a diferencia de los sistemas tradicionales orientados a tareas de clasificación. Este contenido puede abarcar texto, imágenes, audio, vídeo o modelos tridimensionales, suponiendo una ampliación notable del alcance de las aplicaciones basadas en IA.

El auge de esta disciplina surge como consecuencia del crecimiento continuo de la capacidad computacional y del desarrollo de arquitecturas innovadoras como las redes neuronales profundas, los transformers, las redes generativas antagónicas (GANs) y los autoencoders variacionales. Estos modelos aprenden los patrones de un conjunto de entrenamiento y, posteriormente, son capaces de producir nuevas muestras coherentes con los patrones previamente identificados. [4]

Las aplicaciones de la inteligencia artificial generativa se extienden a múltiples sectores, entre los que destacan la educación, el marketing, la ingeniería de software, la salud y los negocios. La democratización de herramientas basadas en estas tecnologías ha permitido que profesionales de diversas áreas accedan a capacidades creativas y analíticas que, hasta hace unos años, estaban limitadas a laboratorios especializados y grandes centros de investigación.

2.2. Procesado del Lenguaje Natural

El Procesamiento del Lenguaje Natural (PLN) es una rama de la inteligencia artificial con el propósito de brindar a las máquinas la capacidad de comprender, interpretar y generar lenguaje de forma autónoma. Es decir, su objetivo principal es permitir la interacción entre los usuarios y los sistemas informáticos utilizando el lenguaje natural como medio de comunicación, eliminando de esta forma las barreras que tradicionalmente suponía la representación formal que requieren los ordenadores.

En sus inicios, alrededor de 1950, los algoritmos consistían en enfoques basados en reglas y gramáticas formales, propios de la lingüística computacional clásica, la cual presentaba una capacidad de generalización limitada como consecuencia de su incapacidad para gestionar la ambigüedad y la variabilidad del lenguaje natural. Con el paso del tiempo, fueron evolucionando hacia modelos estadísticos, los cuales dieron pie al

empleo de la probabilidad y la frecuencia de aparición de las palabras para el modelado, permitiendo la creación de sistemas más robustos ante la variabilidad del lenguaje. Más recientemente, en la década de 2010, tuvo lugar un punto de inflexión significativo con la incorporación de técnicas de aprendizaje profundo. Las redes neuronales (RNN) y posteriormente las redes LSTM (Long Short-Term Memory) permitieron modelar dependencias contextuales de largo alcance en el texto. Por último, tuvo lugar la introducción de la arquitectura de tipo Transformer. Modelos como BERT (Bidirectional Encoder Representations from Transformers) o GPT (Generative Pre-trained Transformer) hacen posible representar el significado de las palabras en su correspondiente contexto, capturando relaciones semánticas y sintácticas complejas, hasta el momento incapturables.

Dentro del ámbito del PLN se engloba una gran cantidad de técnicas y herramientas para cubrir los diferentes niveles de análisis lingüístico. Entre las cuales, las técnicas imprescindibles en cualquier proceso son: el procesamiento del texto, la codificación del texto y la definición del modelo de lenguaje. [6]

Procesado del texto

En todo proceso de PLN es imprescindible comenzar con una fase de preparación de los datos, en la cual el texto se transforma en un formato estructurado y óptimo para su utilización. Este proceso es determinante para la futura efectividad de los modelos de lenguaje. El texto, tal y como se utiliza en el ambiente cotidiano, presenta ciertas características que dificultan su tratamiento, independientemente del idioma del que se trate. Estas dificultades son la consecuencia de la gran variabilidad de la escritura, la información redundante, los elementos no informativos o las estructuras complejas. Para solventar estos problemas se emplean una serie de técnicas de normalización y limpieza.[6, 2]

- **Tokenización:** Segmentar el texto en unidades mínimas, generalmente palabras, para convertirlo en un conjunto de datos manipulable. [2]
- **Eliminación de stopwords y signos de puntuación:** Eliminación de palabras redundantes como los artículos, preposiciones, conjunciones y signos de puntuación. Manteniendo únicamente las palabras que aporten valor. [2]
- **Lematización:** Reducir las palabras a su lema. Con esto se consigue unificar las formas verbales, plurales o variaciones de género. Facilitando el análisis semántico. [2]

Además, dependiendo del contexto y el objetivo pueden aplicarse otras técnicas como la normalización a minúsculas, la corrección ortográfica, eliminación de caracteres especiales o la sustitución por sinónimos.




Figura 2.1: Ejemplo del procesamiento de un corpus de texto.

Codificación del texto

Una vez el texto ha sido procesado es necesario transformarlo en una representación numérica para que los algoritmos puedan emplearlo y sean capaces de capturar el significado y las relaciones entre los elementos que lo componen. Las representaciones más conocidas y empleadas son las siguientes:

- **Bag of Words:** Representa cada documento como un vector donde se indica la frecuencia de aparición de cada palabra. No captura el orden de las palabras ni las relaciones semánticas. [10]

Texto procesado	estudiante	ensayo	investigar	efecto	climático	comunidad
estudiante ensayo efecto climático	1	1	0	1	1	0
estudiante investigar efecto comunidad	1	0	1	1	0	1

Figura 2.2: Ejemplo del procesamiento de un corpus de texto.

- **Term Frequency - Inverse Document Frequency:** Parte de la representación vectorial de BoW, pero pondera cada término en función de su relevancia dentro del corpus. [10]

Texto procesado	estudiante	ensayo	investigar	efecto	climático	comunidad
estudiante ensayo efecto climático	1/4	1/4	0	1/4	1/4	0
estudiante investigar comunidad	1/3	0	1/3	0	0	1/3

Figura 2.3: Ejemplo del procesamiento de un corpus de texto.

- **Word Embeddings:** Representaciones vectoriales densas de dimensión fija que capturan relaciones semánticas y sintácticas entre palabras mediante su posición en un espacio vectorial continuo. Los modelos de esta tipología más utilizados son Word2Vec, GloVe y FastText. Permiten reflejar analogías lingüísticas, pero generan una única representación estática por palabra. [11, 12, 5]




Figura 2.4: Ejemplo del procesamiento de un corpus de texto.

- **Embeddings Contextuales:** Representación vectorial en la que se generan diferentes embeddings para una misma palabra según el contexto asociado. De este modo se consiguen resolver las ambigüedades semánticas. Los ejemplos típicos de estos modelos son ELMo, BERT y GPT. [13, 3, 14]

Modelos de lenguaje

Estos se tratan del último elemento clave en todo proyecto de PLN. Consisten en sistemas diseñados para ser capaces de aprender la estructura y las regularidades del lenguaje natural con el objetivo de estimar la probabilidad de aparición de una palabra o secuencia completa. Para su correcto desempeño es necesario entrenarlos sobre grandes corpus textuales, identificando patrones sintácticos, semánticos y contextuales.

Los modelos más actuales se entrenan mediante técnicas de aprendizaje auto-supervisado, aprovechando enormes cantidades de texto sin etiquetar. Estos modelos preentrenados pueden luego ser ajustados para tareas específicas, logrando buenos rendimientos en una gran cantidad de aplicaciones. [6]

2.3. Retrieval Augmented Generation

Dentro de la rama de Procesamiento de Lenguaje Natural se encuentran las técnicas RAG (Retrieval Augmented Generation). Arquitectura de gran eficacia para dotar a los modelos de lenguaje de acceso dinámico y actualizado a información externa. Permite combinar mecanismos de recuperación documental con un modelo generativo, produciendo en consecuencia respuestas más precisas, fundamentadas y contextualizadas.

En esta técnica se divide el proceso en dos etapas claramente diferenciadas. La primera, etapa de recuperación de la información, donde se localizan los fragmentos de texto relevantes. Y la segunda, etapa de generación de la respuesta, donde se parte de la información recuperada en la etapa previa para elaborar una respuesta coherente y ajustada a la entrada del usuario.

En definitiva, con esta técnica se aprovecha la capacidad generativa de los modelos de lenguaje y la solidez de fuentes de información actualizables, convirtiéndola en una solución apropiada para tareas que requieren precisión, apoyo documental y contexto en la generación de la información. [7]

2.3.1. Recuperación de la información

En esta primera etapa de la arquitectura se tiene como objetivo identificar qué fragmentos de conocimiento serán puestos a disposición del modelo encargado de generar la respuesta de entre todos los documentos almacenados en la base de información correspondiente. Para ello se emplean técnicas de procesamiento del lenguaje natural, recuperación semántica y algoritmos de priorización. Seguidamente se detallan los diferentes componentes clave que la constituyen.

Representación semántica

Teniendo en cuenta todas las técnicas de procesamiento del lenguaje natural para la codificación de conjuntos de texto, en los RAG es necesario almacenar la información de manera codificada para poder garantizar un acceso eficiente. El resultado de este procesamiento de los corpus de texto es un espacio vectorial donde palabras, frases o documentos con significados afines quedan próximos entre sí. De este modo, se consigue garantizar la recuperación de la información relevante basada en el significado de la interacción con el usuario y no únicamente en las condiciones léxicas superficiales. Por tanto, la representación semántica constituye el fundamento sobre el que se construye la recuperación contextualizada propia de las arquitecturas RAG.

Chunking y segmentación

Este proceso consiste en dividir los documentos o corpus de texto extensos en fragmentos más pequeños y manejables para que así puedan ser procesados individualmente por los modelos de lenguaje y posteriormente recuperados de manera más precisa. A cada uno de los segmentos resultantes se les denomina *chunks*. En la implementación de este proceso, es una buena práctica incorporar solapamiento entre los diferentes fragmentos para preservar la continuidad del discurso y evitar la pérdida del contexto en los puntos de corte entre fragmentos. Además, también es muy determinante la correcta elección del tamaño de los chunks. Fragmentos demasiado pequeños pueden perder significado, mientras que fragmentos demasiado extensos pueden dificultar la precisión de la similitud semántica. Una longitud óptima puede contribuir a una recuperación más precisa y granular, evitando la inclusión de información irrelevante cuando solo una pequeña porción de un documento es de interés en función de la consulta realizada por el usuario.

Existen diferentes estrategias de segmentación, cada una con sus ventajas y limitaciones. La más sencilla es la segmentación por longitud fija, donde se dividen los documentos por un número predeterminado de caracteres. La gran ventaja de esta estrategia es la simplicidad de su implementación, mientras que la gran limitación que presenta es que conceptos o ideas que se extienden más allá de la longitud del fragmento pueden quedar separadas dando lugar a la pérdida del contexto semántico. Una estrategia un poco más compleja es la basada en la estructura, en la que se aprovechan los elementos estructurales del documento (párrafos, secciones o capítulos). La ventaja de esta implementación es que en algunos casos estas divisiones estructurales se corresponden con unidades semánticas coherentes. Sin embargo, esta limitada por el hecho de que en algunos casos los documentos no poseen una estructura clara y bien definida. Por último, una estrategia más compleja es la segmentación semántica. En esta, mediante técnicas de procesamiento del lenguaje natural, se identifican los límites naturales en el flujo de las ideas o tópicos. Para ello se recurre a algoritmos como TextTiling o métodos basados en coherencia semántica con los que se analizan las transiciones de tópicos en el texto y se establecen los puntos de segmentación donde se dan los cambios temáticos significativos. La gran limitación de esta estrategia es la complejidad del algoritmo y la capacidad de procesamiento necesaria para ser implementado. [6, 7]

Bases de datos vectoriales e indexado

Las bases de datos vectoriales son el componente especializado para el almacenamiento y consulta de las codificaciones de los *chunks* de texto de manera eficiente. Con ellas se hace posible la gestión óptima de la información y la búsqueda de similitudes a gran escala. A diferencia de las bases de datos convencionales para el almacenamiento de datos estructurados, estas están diseñadas para operaciones de búsqueda por similitud en espacios vectoriales continuos.

Para poder garantizar una búsqueda eficiente por similitud, las bases de datos vectoriales implementan algoritmos de búsqueda aproximada del vecino más cercano (Approximate Nearest Neighbor, ANN) que sacrifican una pequeña cantidad de precisión a cambio de mejoras en eficiencia. Estos algoritmos organizan los datos en vectores, permitiendo de este modo descartar rápidamente regiones del espacio vectorial con alta probabilidad de no contener los vecinos más cercanos.

Además, en estos sistemas de almacenamiento se emplean índices (procedimiento conocido como indexación) con los que se consigue realizar una búsqueda eficiente de los vecinos más cercanos bajo distintas métricas de similitud, mitigando el elevado coste asociado a la búsqueda exacta en espacios de alta dimensionalidad. Con este contexto, los algoritmos de indexación pueden agruparse en cuatro grupos. [10, 15]

- **Algoritmos basados en particionamiento del espacio:** Con estos métodos se estructura el conjunto de vectores mediante divisiones recursivas del espacio métrico, generando estructuras jerárquicas con las que se consigue destacar regiones completas durante la búsqueda. De este modo, para cada consulta se exploran únicamente aquellas regiones potencialmente relevantes. La limitación de este grupo de métodos es que sus prestaciones se ven mermadas de manera significativa a medida que aumentan considerablemente las dimensiones del espacio vectorial.
- **Algoritmos basados en hashing:** Con estos métodos se transforman las codificaciones del texto originales en representaciones compactas preservando la noción de cercanía previamente existente. De este modo, reduciendo la dimensión de los vectores se consigue reducir los tiempos de búsqueda. Aunque, este conjunto de métodos están limitados por la relación directa entre la precisión, la cantidad de funciones hash y el consumo de memoria. Además, se requiere más almacenamiento para las tablas hash asociadas a las transformaciones.
- **Algoritmos basados en cuantificación vectorial:** Con estos métodos se estima la distancia entre vectores y se almacena en tablas, de este modo se evita la realización de operaciones aritméticas directas sobre los valores originales. Esta estrategia facilita la búsqueda eficiente con vectores de dimensión elevada o en escenarios con recursos computacionales limitados. Sin embargo, la limitación que presentan es que la aproximación de las distancias puede afectar a la precisión de las búsquedas, requiriendo una fase de entrenamientos previa.
- **Algoritmos basados en grafos de proximidad:** Con estos métodos se representa el espacio vectorial como un grafo en el que los nodos se corresponden con los vectores y las aristas asocian los elementos cercanos en función de la métrica de similitud asociada. Esta estrategia funciona eficientemente en espacios de elevada dimensión. Permitiendo alcanzar un equilibrio favorable entre latencia y precisión en las búsquedas al combinar la exploración global con el refinamiento local. Como limitación, estos métodos requieren más memoria y un coste de construcción e inserción más elevado que el resto de grupos de métodos.

Recuperación avanzada de la información

En muchas situaciones y contextos, una única formulación por parte de usuario puede resultar insuficiente para capturar toda la información relevante disponible en los documentos sobre los que se ha implementado el sistema. Esto es debido a la dificultad para, con una sola consulta, reflejar de manera precisa la necesidad informativa real, ya sea por ambigüedad semántica del idioma, falta de precisión terminológica o desconocimiento del vocabulario específico empleado en los documentos técnicos que dan origen a la implementación.

Con el propósito de de solucionar dichas limitaciones, surgen los sistemas y técnicas de búsqueda avanzada. Estos consisten en un conjunto de estrategias orientadas a enriquecer y diversificar el proceso de recuperación de la información. Entre estas estrategias destacan los métodos de expansión y reformulación de consultas, cuyo objetivo es generar múltiples versiones de la consulta inicial del usuario.

La expansión de consultas se basa en incorporar términos adicionales relacionados semánticamente con los originales, permitiendo ampliar el espacio de búsqueda y reducir el riesgo de omitir documentos o corpus de texto relevantes. Mientras que, la reformulación se basa en generar variantes completas de la consulta original en las que se preserve el propósito y significado. Como resultado de ambas técnicas se obtiene un conjunto de consultas alternativas que se procesan de forma independiente reflejando distintas perspectivas o versiones de la consulta inicial.

Fusión de rankings como mecanismo de integración de resultados

La utilización de múltiples consultas implica la generación de diversas listas de documentos recuperados, cada una de ellas asociada a una formulación distinta de la consulta original. Como consecuencia, se hace necesario el empleo de técnicas capaces de integrar de forma coherente toda la información recuperada en el proceso.

En este contexto, emergen con especial relevancia los algoritmos de fusión de rankings, cuyo objetivo es combinar varias ordenaciones de los documentos en una clasificación global. Estos algoritmos se fundamentan en tratar de dar mayor relevancia a aquellos documentos que aparecen de forma regular en las mejores posiciones de todos los rankings.

La fusión de rankings brinda la posibilidad de aprovechar la complejidad del sistema para integrar de forma óptima la información recuperada en la realización de un conjunto de consultas de búsqueda de forma independiente, reduciendo el sesgo asociado a la realización de una única formulación en la búsqueda. Como resultado se consigue aumentar la cantidad de información relevante recuperada y, por consecuencia, se mejora el *recall* del sistema.

Re-ranking supervisado mediante modelos Cross-Encoder

En algunas implementaciones, tras la fase de generación de múltiples consultas y la fase de fusión de resultados, es habitual implementar una etapa adicional de re-ranking supervisado con tal de mejorar la precisión en las primeras posiciones del ranking final.

Dentro de este contexto, los modelos Cross-Encoder representan una de las aproximaciones más precisas para el re-ranking supervisado. Permiten procesar los pares de textos consulta-documento de forma conjunta dentro de una única arquitectura. Permitiendo, de este modo, modelar explícitamente las interacciones entre los términos de la consulta y los del documento, capturando las relaciones semánticas complejas. Dando, como resultado, una puntuación de relevancia para cada par consulta-documento con la que se puede reordenar los documentos candidatos.

Con la inclusión de esta etapa adicional en las modelizaciones, se consigue mejorar de forma significativa la calidad del ranking final, especialmente en las primeras posiciones, sin comprometer a la escalabilidad global del sistema. Mejorando, en la gran mayoría de escenarios, la precisión de la recuperación realizada. [9]

2.3.2. Generación de la respuesta

Una vez se tiene identificada toda la información relevante de las fuentes de datos, los documentos, se debe integrar en un modelo de inteligencia artificial generativa para producir una respuesta final coherente, precisa y alineada con la consulta del usuario. La principal característica de los sistema RAG es su capacidad para integrar información externa recuperada dinámicamente, lo que permite fundamentar las respuestas en contenido actualizado y específico del ámbito.

En esta fase de la arquitectura, el modelo recibe como entrada tanto la consulta del usuario como la información recuperada en la fase de recuperación. Teniendo este la función de sintetizar, interpretar y estructurar la información proporcionada de manera que se consiga satisfacer la intención del usuario, manteniendo consistencia semántica y evitando la introducción de información no contemplada en las fuentes recuperadas.

Con tal de satisfacer las necesidades, los modelos de lenguaje suelen estar basados en arquitecturas transformer autorregresivas, capaces de modelar dependencias a largo plazo y tener en consideración el contexto de entrada proporcionado. Pero, en la gran mayoría de implementaciones el desempeño de este modelos está muy influenciado por el mensaje de entrada, lo que hace imprescindible en toda implementación un prompt de interacción con el modelo correctamente diseñado. [7]

Diseño del prompt adecuado

El prompt es la vía de comunicación entre el sistema RAG y el modelo generativo, en él se define tanto la tarea a realizar por el modelo como la información de la que este dispone para realizarla. Siendo este el motivo por el cual un diseño adecuado de este es determinante en la implementación para lograr respuestas coherentes y precisas. [8]

Desde el punto de vista teórico, un buen prompt debe cumplir las siguiente características:

- **Claridad:** Las instrucciones deben de ser fáciles de interpretar y se deben evitar ambigüedades que puedan dar lugar a respuestas imprecisas o fuera de contexto.
- **Especificidad:** Es conveniente definir el formato de salida deseado y el nivel de detalle esperado en la respuesta.
- **Contexto:** Es importante proporcionarle al modelo toda la información relevante a tener en cuenta para la generación de la respuesta.
- **Longitud:** Se debe mantener un equilibrio entre la cantidad de información proporcionada al modelo y la capacidad de este para procesarla eficientemente. Tratando de evitar tanto la omisión de datos relevantes como la sobrecarga informativa.

2.3.3. Evaluación de modelos

Convencionalmente, en implementaciones basadas en técnicas de aprendizaje automático tradicionales, la eficacia puede medirse con estadísticos como son R-cuadrado, AIC o BIC entre muchos otros. Sin embargo, en los sistemas RAG poder evaluar la eficacia de los modelos resulta más complejo. Esto se debe a que las respuestas están compuestas por texto no estructurado.

Con el objetivo de satisfacer esta problemática, surge el marco TRIAD. Se trata de un modelo de evaluación con un enfoque multidimensional, en el que se tienen en cuenta tres perspectivas de evaluación: Relevancia del contexto, Fidelidad y Relevancia de la respuesta.




Figura 2.5: Esquema del marco TRIAD para la evaluación de arquitecturas RAG.

Relevancia del contexto

En esta componente de la evaluación se mide la eficacia del sistema para identificar los documentos más relevantes en función de la consulta realizada por el usuario. Imprescindible para asegurar que el contexto proporcionado al modelo generador de la respuesta sea pertinente, coherente y preciso. Las métricas necesarias para valorar esta perspectiva se corresponden con las siguientes:

- **Precisión:** Medida que permite cuantificar la relación entre el número total de documentos relevantes recuperados y el número total de documentos recuperados.

$$\text{Precisión} = \frac{\text{Número total de documentos relevantes recuperados}}{\text{Número total de documentos recuperados}} \quad (2.1)$$

- **Recall:** Medida para evaluar la relación entre el número de documentos relevantes recuperados y el número total de documentos relevantes en la base de datos.

$$\text{Recall} = \frac{\text{Número total de documentos relevantes recuperados}}{\text{Número total de documentos relevantes}} \quad (2.2)$$

- **F1:** Medida que permite evaluar el equilibrio entre la exactitud (precisión) y la exhaustividad (recall).

$$F1 = \frac{2 \times (\text{Precisión} \times \text{Recall})}{\text{Precisión} + \text{Recall}} \quad (2.3)$$

- **Mean Reciprocal Rank:** Métrica que evalúa la capacidad del sistema para situar el primer documento relevante en las primeras posiciones del ranking devuelto. Para cada consulta del usuario se consulta el recíproco de la posición ocupada por el primer documento relevante y posteriormente se promedia sobre el conjunto total de consultas.

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} \quad (2.4)$$

donde rank_i representa la posición del primer documento relevante para la consulta i , y $|Q|$ el número total de consultas evaluadas.

- **Mean Average Precision:** Métrica que considera tanto la precisión como la posición de todos los documentos relevantes en el ranking. Para cada consulta se calcula la precisión en cada posición donde aparece un documento relevante y posteriormente se promedia sobre el total de las consultas.

$$\text{MAP} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} AP_i \quad (2.5)$$

donde AP_i es la *Average Precision* asociada a la consulta i .

Fidelidad

Esta componente constituye el eje central de la evaluación, permitiendo validar si la respuesta generada por el sistema es consistente con la información contenida en los documentos resultantes de la fase de recuperación. Es decir, la fidelidad cuantifica el grado en que las afirmaciones generadas en la fase de generación de la respuesta pueden ser derivadas, inferidas legítimamente a partir de dicho contexto. Una respuesta se considera con alto nivel de fidelidad cuando no introduce información que exceda o contradiga las fuentes disponibles.

Desde el punto de vista metodológico, se puede evaluar esta mediante tres metodologías diferentes. La primera es la evaluación manual, esto implica verificar cada respuesta generada con los documentos de origen para asegurar que todas las afirmaciones estén respaldadas. La segunda se basa en herramientas automatizadas, estas realizan una comparación de la respuesta generada con la base de datos con tal de identificar inexactitudes sin la necesidad de intervención humana en el proceso. Y, la tercera se basa en verificaciones de consistencia, estas se basan en verificar si el modelo implementado proporciona la misma información en diferentes consultas, asegurando que dicho modelo sea confiable y no genere contradicciones.

Relevancia de la respuesta

En esta componente de la evaluación se mide la eficacia del sistema para la generación de la respuesta tomando como punto de partida la información recuperada. Es decir, se trata de evaluar qué tan bien la respuesta generada es capaz de abordar la consulta del usuario. Para ello se emplean las siguientes métricas:

- **BLEU** (Bilingual Evaluation Understudy): Medida que permite evaluar la superposición entre la respuesta y un conjunto de respuestas de referencia, cuantificando la similitud entre la respuesta generada y las de referencia. Para su obtención se calcula la superposición de n -gramos entre la respuesta generada y las respuestas de referencia.

$$\text{BLEU} = \text{BP} \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right) \quad (2.6)$$

donde BP es la penalización de las respuestas cortas p_n es la precisión de los n -gramos y w_n son los pesos de cada nivel de n -gramo.

- **ROUGE** (Recall-Oriented Understudy for Gisting Evaluation): Medida que cuantifica la superposición de n -gramos, secuencias y pares de palabras entre la respuesta generada y las respuestas de referencia, considerando tanto el recall como la precisión.

$$\text{ROUGE-N} = \frac{\sum_{\text{gram}_n \in \text{Referencia}} \text{Count}_{\text{match}}(\text{gram}_n)}{\sum_{\text{gram}_n \in \text{Referencia}} \text{Count}(\text{gram}_n)} \quad (2.7)$$

donde $\text{Count}_{\text{match}}(\text{gram}_n)$ es la cantidad de n -gramas que coinciden entre el texto de la respuesta generada y las de referencias y $\text{Count}(\text{gram}_n)$ es la cantidad total de n -gramas en las respuestas de referencia.

- **METEOR** (Metric for Evaluation of Translation with Explicit ORdering): Medida que evalúa la similitud de la respuesta generada y las respuestas de referencia teniendo en consideración la sinonimia, stemming y el orden de las palabras.

$$\text{METEOR} = F_{\text{mean}}(1 - P_{\text{penalty}}) \quad (2.8)$$

donde F_{mean} es la media armónica de la precisión y recall y P_{penalty} es una penalización por el orden incorrecto de las palabras.

Bibliografía

- [1] AACSB International. Master's enrollment trends at aacsb schools: A shifting landscape, 2024. Accessed: 2026-04-14.
- [2] Steven Bird, Ewan Klein, and Edward Loper. *Natural Language Processing with Python*. O'Reilly Media, 2009.
- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL*, 2019.
- [4] Roberto Gozalo-Brizuela and Eduardo C. Garrido-Merchán. A survey of generative ai applications. *Journal of Computer Science*, 20(8):801–818, 2024.
- [5] Armand Joulin, Edouard Grave, Piotr Bojanowski, and Tomas Mikolov. Bag of tricks for efficient text classification. *arXiv preprint arXiv:1607.01759*, 2017.
- [6] Daniel Jurafsky and James H. Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*. Prentice Hall, 3rd edition, 2026.
- [7] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [8] Pengfei Liu, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi, and Graham Neubig. Pre-train, prompt, and predict: A systematic survey of prompting methods in nlp. *arXiv preprint arXiv:2107.13586*, 2021.
- [9] Tie-Yan Liu. Learning to rank for information retrieval. *Foundations and Trends in Information Retrieval*, 2009.
- [10] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [11] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.
- [12] Jeffrey Pennington, Richard Socher, and Christopher D. Manning. Glove: Global vectors for word representation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014.

- [13] Matthew E. Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, and Luke Zettlemoyer. Deep contextualized word representations. In *Proceedings of NAACL*, 2018.
- [14] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving language understanding by generative pre-training. *OpenAI Technical Report*, 2018.
- [15] Xinyu Zhang et al. A survey on vector database: Storage, indexing and query processing. *arXiv preprint arXiv:2308.XXXXX*, 2023.